

面向高效大模型推理的状态转移对齐式 Latent Reasoning Token 学习

研究提案 (Research Proposal)

2026 年 6 月 16 日

1 研究课题介绍

显式 Chain-of-Thought (CoT) 能够显著提升大语言模型在数学、逻辑、常识和规划任务上的多步推理能力，但其代价也很明显：推理链越长，生成 token 数越多，推理延迟、显存占用和 KV-cache 开销越高。近年来，latent reasoning 试图用连续隐向量或隐式 reasoning tokens 替代显式文本推理链，在保留推理能力的同时降低推理成本。

现有工作已经从多个角度探索了这一方向。例如：

- **COCONUT** 将显式推理逐步迁移到连续 latent space；
- **CODI** 通过自蒸馏将 CoT 压缩到连续空间；
- **SoftCoT** 使用辅助模型生成 soft thought tokens；
- **SIM-CoT** 引入 step-level supervision 以缓解 latent collapse；
- **KaVa** 进一步使用压缩后的 teacher KV-cache 作为监督信号。

这些方法证明了 latent reasoning 的潜力，但也暴露出一个核心问题：当少量 latent tokens 需要压缩多个显式 CoT steps 时，模型究竟应该让每个 latent token 学到什么？

本课题提出一个更明确的研究视角：**latent token 不应仅仅被看作某段文本 step 的隐式替代物，也不应只被监督到最终答案或 endpoint hidden state，而应被建模为对 Transformer 内部计算状态执行更新的 transition operator**。也就是说，一个 latent token 对应一段显式 reasoning span 对模型内部状态造成的宏观状态转移。

—

2 核心研究问题

给定问题 x 、显式 CoT 推理链 r 和最终答案 y ，将 r 划分为 K 个连续 reasoning spans：

$$r = [b_1, b_2, \dots, b_K]$$

传统 latent reasoning 方法通常让 student 生成:

$$x, z_1, z_2, \dots, z_K, y$$

其中 z_k 是 latent reasoning token。

关键问题是: 当 K 小于显式 CoT 的细粒度步骤数时, 每个 z_k 如何学习多个文本步骤合并后产生的内部推理更新?

本课题的核心假设是:

z_k 应学习 *reasoning span* b_k 对 *Transformer computational state* 造成的 *state transition*。

也就是说, z_k 的监督目标不是复原某一段文本, 而是复现 teacher 从 s_{k-1} 到 s_k 的内部状态变化。

—

3 研究内容

3.1 Teacher-Student Latent Reasoning 框架

构建一个包含 CoT teacher 和 latent student 的蒸馏框架:

- **Teacher** 输入问题、显式 reasoning spans、boundary markers 和答案;
- **Student** 输入问题、少量 latent reasoning tokens 和答案;
- Teacher 在每个 span boundary 后抽取多层 hidden states, 作为显式推理状态演化轨迹;
- Student 在每个 latent token 后抽取对应 hidden states, 作为隐式推理状态演化轨迹。

Teacher 输入形式可表示为:

$$x, b_1, \langle m_1 \rangle, b_2, \langle m_2 \rangle, \dots, b_K, \langle m_K \rangle, y$$

Student 输入形式可表示为:

$$x, \langle \text{bot} \rangle, z_1, z_2, \dots, z_K, \langle \text{eot} \rangle, y$$

其中 $\langle m_k \rangle$ 是 boundary marker, 用于稳定抽取第 k 个 reasoning span 结束后的 teacher computational state。

3.2 状态转移对齐监督

对 teacher 和 student 分别定义状态差分:

$$\Delta s_k^T = s_k^T - s_{k-1}^T$$

$$\Delta s_k^S = s_k^S - s_{k-1}^S$$

其中 s_k^T 表示 teacher 完成第 k 个 reasoning span 后的内部状态, s_k^S 表示 student 执行第 k 个 latent token 后的内部状态。

核心损失设计为:

$$L_{\text{transition}} = \sum_k d(\Delta s_k^S, \text{stopgrad}(\Delta s_k^T))$$

为了防止模型只匹配状态差分但整体 hidden state 逐渐漂移, 加入 anchor loss:

$$L_{\text{anchor}} = \sum_k d(s_k^S, \text{stopgrad}(s_k^T))$$

总损失为:

$$L = L_{\text{task}} + \lambda L_{\text{transition}} + \alpha L_{\text{anchor}}$$

其中 L_{task} 是答案生成或标准语言建模损失, λ 与 α 控制状态转移监督和状态锚定监督的权重。

3.3 One-Step Alignment 以缓解 Exposure Mismatch

实际训练中存在一个重要 mismatch: teacher transition 发生在 teacher predecessor state s_{k-1}^T 上, 而 student 推理时 transition 发生在 student rollout state s_{k-1}^S 上。如果只在 teacher-forced prefix 下训练, 推理时可能产生 exposure mismatch; 如果只在 student rollout 下训练, 早期 latent 错误又可能污染后续监督。

因此可以设计 one-step bridge alignment, 使同一个 latent token z_k 在两类 predecessor states 下都能执行相同 teacher transition:

1. **teacher-predecessor bridge**: 将 student 生成的 latent embedding 插入 teacher text prefix 后, 抽取该位置后的 state;
2. **student-rollout bridge**: 在真实 student latent prefix 下执行 z_k , 抽取对应 state;
3. **bridge consistency**: 约束二者不应执行两个完全不同的 transition。

对应 bridge loss 可写为:

$$L_{\text{bridge}} = \sum_k d(\hat{s}_k^{S \leftarrow T}, \text{stopgrad}(s_k^T)) + \rho \sum_k d(\hat{s}_k^{S \leftarrow S}, \text{stopgrad}(s_k^T)) + \xi \sum_k d(\hat{s}_k^{S \leftarrow T}, \hat{s}_k^{S \leftarrow S})$$

该设计的目标是让 latent token 同时适应 teacher-forced 训练环境和真实 student rollout 推理环境。

3.4 Latent Token 可解释性与稳定性分析

为了验证 latent token 是否真的学习了不同 reasoning spans 的状态转移, 而不是 collapse 成同质化表示, 本课题将设计以下分析:

- latent token 间的表示多样性分析;

- 不同 layer 的 transition alignment 可视化；
- auxiliary decoder / probing classifier 还原每个 latent token 对应的推理语义角色；
- 不同 reasoning length 下的训练稳定性曲线；
- OOD 数据集上的 latent transition drift 分析。

—

4 研究目标

本课题拟实现以下目标：

1. 提出一种面向 latent reasoning 的状态转移对齐训练框架，使每个 latent token 学习显式 CoT span 对模型内部状态造成的功能性更新。
2. 在保持较低推理 token 成本的前提下，使 latent student 在数学推理、逻辑推理和常识推理任务上接近或超过显式 CoT、COCONUT、CODI、SoftCoT、SIM-CoT 等基线。
3. 缓解多 latent token 训练中的 latent collapse、semantic homogenization 和 exposure mismatch 问题。
4. 建立一套 latent reasoning 的诊断指标，包括状态转移一致性、语义多样性、OOD 稳定性、效率-性能 trade-off 和 failure mode。
5. 为高效推理模型提供一种更可解释、更稳定的隐式推理监督范式。

—

5 研究方案

5.1 数据构建

选择包含显式推理链或可生成显式推理链的数据集。对于每个样本，构造如下字段格式：

```
{
  "question": "...",
  "answer": "...",
  "steps": ["...", "...", "..."],
  "spans": [["step1", "step2"], ["step3"], ["step4", "step5"]]
}
```

Span 划分可采用以下策略：

- **固定步数划分：**将 CoT 均匀划分为 K 个 spans；

- **语义边界划分**: 按解题阶段、公式推导、子目标变化划分;
- **动态压缩划分**: 根据 token 长度或 hidden state 变化幅度划分;
- **随机 span augmentation**: 训练时随机合并相邻 steps, 提高鲁棒性。

5.2 模型选择

可从小规模到中等规模逐步推进:

- **初始验证**: GPT-2 / Qwen2.5-0.5B / Qwen2.5-1.5B;
- **主实验**: Llama-3.2-1B / Llama-3.2-3B / Qwen2.5-3B;
- **扩展实验**: Llama-3.1-8B / Qwen2.5-7B。

如果算力有限, 可优先选择 COCONUT 或 CODI 的开源代码作为基础框架, 在其 hidden-state distillation 或 continuous thought 机制上加入 transition alignment。

5.3 训练流程

1. **CoT teacher 训练或加载**: 使用显式 CoT 数据对 teacher 进行监督微调, 或直接使用已有 CoT-tuned model。
2. **Teacher state extraction**: 在 boundary marker 处抽取多层 hidden states, 构建 teacher state trajectory。
3. **Student latent initialization**: 使用 special latent tokens、hidden projection 或 soft token embedding 初始化 latent reasoning tokens。
4. **Transition alignment training**: 联合优化答案生成损失、transition loss、anchor loss 和 bridge loss。
5. **Curriculum training**: 从较少 latent tokens、较短 CoT、较简单任务开始, 逐步增加 reasoning length 与压缩率。
6. **Evaluation**: 在 in-domain 与 OOD 数据集上评估准确率、效率、稳定性和可解释性。

5.4 对比基线

实验中建议包含以下基线:

- **Direct Answer**: 不使用 CoT, 直接输出答案;
- **Explicit CoT**: 生成完整显式推理链;
- **Short CoT**: 手工或模型压缩后的短推理链;

- **COCONUT**: 连续 latent thought 基线;
- **CODI**: hidden-state self-distillation 基线;
- **SoftCoT**: soft thought token 基线;
- **SIM-CoT**: step-level supervision 基线;
- **KaVa-style KV matching**: 压缩 KV-cache 蒸馏思路;
- **Proposed**: 状态转移对齐式 latent reasoning。

5.5 消融实验

表 1: 消融实验规划表

消融项	目的
去掉 transition loss	验证状态转移监督是否核心有效
去掉 anchor loss	检查是否出现 hidden state drift
去掉 bridge loss	验证 exposure mismatch 缓解效果
只对齐 endpoint hidden state	与 CODI 类方法比较
只重构文本 step	与 SIM-CoT 类 step decoder 监督比较
不同 K 值	测试压缩率和性能关系
不同 layer 组合	分析哪一层包含更强 reasoning transition
不同 distance function	比较 L1、L2、cosine、smooth L1、CKA 等
不同 span 划分策略	分析语义划分与均匀划分的差异

5.6 评价指标

表 2: 评价指标分类表

指标类别	具体指标
任务性能	Accuracy、Exact Match、pass@k
推理效率	输出 token 数、latency、FLOPs、KV-cache memory
压缩效果	CoT token reduction ratio、accuracy-cost trade-off
稳定性	多 seed 方差、训练 collapse rate、OOD drop
表征质量	latent diversity、state transition similarity、layer-wise alignment
可解释性	latent probing accuracy、decoder reconstruction quality、错误类型分析

6 技术路线

显式 CoT 数据

↓

CoT span 划分与 boundary marker 插入

↓

Teacher CoT 推理与 hidden state trajectory 抽取

↓

Student latent token rollout

↓

状态转移对齐:

- transition loss
- anchor loss
- one-step bridge loss

↓

联合训练:

- answer generation
- latent transition distillation
- rollout consistency

↓

实验评估:

- in-domain accuracy
- OOD robustness
- token/latency/memory cost
- latent interpretability

↓

机制分析与论文撰写

7 可借助的数据集

8 可借助的开源代码

9 预期创新点

1. 监督目标创新: 将 latent token 的学习目标从文本 step 复原或 endpoint hidden matching, 转为 reasoning span 引发的内部状态转移对齐。

表 3: 可用数据集列表

数据集	用途	参考链接
GSM8K	主训练与数学推理验证, 包含高质量小学数学应用题	arXiv:2110.14168
MATH	更难的竞赛数学推理, 适合测试长链推理能力	arXiv:2103.03874
SVAMP	数学应用题 OOD 扰动测试	arXiv:2103.07191
GSM-Hard	GSM8K 的困难变体, 可用于泛化测试	可通过 CODI/相关仓库使用
MultiArith	多步算术推理测试	可通过 CODI/公开评测脚本使用
PrOntoQA	形式逻辑和 proof planning 测试	arXiv:2210.01240
CommonsenseQA	常识推理测试	arXiv:1811.00937
StrategyQA	隐式策略推理与问题分解	arXiv:2101.02235
BIG-Bench Hard	多类型通用推理压力测试	arXiv:2210.09261
BIG-Bench Extra Hard	更困难的通用推理评测	arXiv:2502.19187

表 4: 可借鉴开源项目列表

开源项目	可借鉴内容	仓库链接
COCONUT	连续 latent thought 框架, 数据处理和训练流程	facebookresearch/coconut
CODI	隐状态自蒸馏、latent probing、基础数据集评测	zhenyi4/codi
SIM-CoT	step-level 增强框架、latent collapse 诊断	InternLM/SIM-CoT
SoftCoT	soft thought token、test-time scaling 探索	xuyige/SoftCoT
Transformers	模型加载、hidden state 抽取、基础训练设施	huggingface/transformers
lm-eval-harness	多任务 LLM 统一评测框架	EleutherAI/lm-eval-harness

2. **机制解释创新:** 把 latent token 明确定义为 Transformer computational state 的 transition operator, 从而解释为什么少量 latent tokens 可以压缩多步 CoT。
3. **训练稳定性创新:** 通过 anchor loss 和 bridge loss 缓解 hidden state drift、latent collapse 和 exposure mismatch。
4. **评估角度创新:** 不仅报告 accuracy 和 token cost, 还分析 latent transition consistency、semantic diversity 和 OOD state drift。

10 可能风险与应对策略

表 5: 潜在风险及应对方案

风险	表现	应对策略
Novelty 被覆盖	SIM-CoT/KaVa 已做强监督	突出 transition operator 与状态更新，而非 step decoder
隐状态对齐不稳定	loss 难收敛或出现训练 collapse	使用 curriculum、layer selection、normalized distance 及 warm
算力成本较高	需要抽取多层 hidden states	先做 GPT-2/1B 规模验证，再扩展到 3B/8B
OOD 提升不明显	只在 GSM8K 有效	加入 SVAMP、PrOntoQA、StrategyQA、BBH 等跨任务测试
可解释性证据弱	latent token 难以映射到语义	加辅助 decoder/probing，但强调主方法不依赖推理时 decoder